

Propozycja tematu pracy magisterskiej

**Implementacja i optymalizacja algorytmów uczenia
głębokiego do klasyfikacji arytmii w niskokosztowych
systemach monitoringu EKG z wykorzystaniem
technologii Edge AI**

Student: Łukasz Guziczak

Nr albumu: 105093

Kierunek: Informatyka

Specjalność: Sztuczna inteligencja i uczenie maszynowe

Promotor: dr inż. Piotr Ciskowski

Uniwersytet WSB Merito Wrocław

Data: 29 czerwca 2025

Spis treści

1	Temat pracy	2
2	Uzasadnienie wyboru tematu i cel pracy	2
2.1	Motywacja	2
2.2	Cel główny	2
2.3	Cele szczegółowe	2
3	Hipotezy badawcze	3
4	Metodologia badawcza	3
4.1	Architektury modeli	3
4.2	Techniki optymalizacji	3
4.3	Datasety	3
4.4	Metryki ewaluacji	3
5	Plan realizacji	4
5.1	Harmonogram	4
5.2	Kamienie milowe	4
6	Aktualny stan projektu	4
7	Oczekiwane rezultaty	5
7.1	Wkład naukowy	5
7.2	Wkład praktyczny	6
	Bibliografia podstawowa	6

1 Temat pracy

PL: Implementacja i optymalizacja algorytmów uczenia głębokiego do klasyfikacji arytmii w niskokosztowych systemach monitoringu EKG z wykorzystaniem technologii Edge AI

EN: Implementation and Optimization of Deep Learning Algorithms for Arrhythmia Classification in Low-Cost ECG Monitoring Systems Using Edge AI Technology

2 Uzasadnienie wyboru tematu i cel pracy

2.1 Motywacja

Choroby układu krążenia stanowią główną przyczynę zgonów globalnie. Dostęp do profesjonalnej diagnostyki EKG jest ograniczony ze względu na:

- Wysokie koszty profesjonalnych urządzeń ($>10\,000$ PLN)
- Brak wykwalifikowanego personelu w regionach oddalonych
- Konieczność fizycznej wizyty w placówce medycznej

Projekt proponuje rozwiązanie wykorzystujące:

- Tani moduł AD8232 (<20 PLN) + mikrokontroler RP2040 (<10 PLN)
- Algorytmy deep learning do automatycznej analizy
- Przetwarzanie Edge AI eliminujące potrzebę internetu

Autor opracował działający prototyp systemu z oprogramowaniem dostępnym w repozytorium open-source: <https://github.com/guziczak/ad8232>. Repozytorium zawiera:

- `main_scaled.py` – firmware MicroPython wgrywany na mikrokontroler RP2040
- `visualizer_scaled.py` – aplikacja PC do wizualizacji sygnału EKG w czasie rzeczywistym

2.2 Cel główny

Opracowanie kompletnego systemu monitoringu EKG wykorzystującego uczenie głębokie do automatycznej klasyfikacji arytmii, działającego w czasie rzeczywistym na urządzeniach embedded o ograniczonych zasobach.

2.3 Cele szczegółowe

1. **Walidacja sprzętowa:** Zbadanie możliwości diagnostycznych układu AD8232 w porównaniu z profesjonalnym EKG
2. **Rozwój modeli AI:** Implementacja i porównanie architektur CNN, LSTM, CAT-Net dla klasyfikacji arytmii
3. **Optymalizacja dla Edge:** Kompresja modeli (kwantyzacja, pruning) do rozmiaru $<500\text{KB}$
4. **Walidacja kliniczna:** Osiągnięcie dokładności $>90\%$ na datasetach MIT-BIH [1] i PTB-XL [2]

3 Hipotezy badawcze

- H1:** Sygnał z układu AD8232 po preprocessingu umożliwia detekcję podstawowych arytmii (AF, PVC, bradykardia, tachykardia) z czułością $>85\%$
- H2:** Architektury CNN dedykowane sygnałom 1D osiągają lepszy stosunek dokładność/złożoność niż LSTM dla single-lead EKG
- H3:** Kwantyzacja INT8 i pruning redukują rozmiar modelu o $>75\%$ przy spadku dokładności $<5\%$
- H4:** Edge AI zapewnia latencję $<100\text{ms}$, umożliwiając real-time monitoring bez połączenia z chmurą

4 Metodologia badawcza

4.1 Architektury modeli

1. **CNN 1D** - Adaptacja MobileNet dla sygnałów czasowych
2. **LSTM z uwagą** - Analiza długoterminowych zależności w EKG
3. **CAT-Net** - Hybrydowa architektura Convolution-Attention-Transformer
4. **Ensemble** - Voting classifier łączący powyższe

4.2 Techniki optymalizacji

- **Kwantyzacja:** Post-training quantization FP32 \rightarrow INT8
- **Pruning:** Magnitude-based i structured pruning
- **Knowledge Distillation:** Transfer z dużego modelu-nauczyciela
- **NAS:** Automatyczne wyszukiwanie optymalnej architektury

4.3 Datasetsy

- **MIT-BIH Arrhythmia Database [1]** - 48 nagrań 30-minutowych, gold standard dla arytmii
- **PTB-XL Database [2]** - 21,837 nagrań 12-odprowadzeniowych, największy publiczny dataset
- **Własne dane** - Zebrane układem AD8232 do fine-tuningu

4.4 Metryki ewaluacji

- **Skuteczność:** Accuracy, Sensitivity, Specificity, F1-score per klasa
- **Wydajność:** Latencja (ms), FPS, zużycie RAM/Flash
- **Energia:** Pobór prądu (mA), czas pracy na baterii

5 Plan realizacji

5.1 Harmonogram

1. **Październik-Listopad 2025:** Przegląd literatury, analiza state-of-the-art
2. **Grudzień 2025:** Walidacja sprzętu AD8232, porównanie z profesjonalnym EKG
3. **Styczeń-Marzec 2026:** Rozwój i trening modeli ML na datasetach
4. **Kwiecień-Maj 2026:** Kompresja modeli i deployment na RP2040
5. **Czerwiec 2026:** Testy systemu, walidacja cross-dataset

5.2 Kamienie milowe


M1: Działający prototyp hardware z podstawowym preprocessingiem

M2: Wytrenowane modele z accuracy $>90\%$ na MIT-BIH


M3: Model skompresowany do $<500\text{KB}$ działający na RP2040

M4: Kompletny system z dokumentacją open-source

6 Aktualny stan projektu



Rysunek 1: Obecny prototyp systemu EKG z modulem AD8232 i wizualizacją real-time



Rysunek 2: Prototyp hardware'u: mikrokontroler RP2040-Zero z modulem AD8232 oraz elektrodami EKG

Dotychczas zrealizowano:

- Działający hardware (RP2040 + AD8232)
- Firmware w MicroPython (250 Hz sampling)
- PC software do wizualizacji real-time

Zidentyfikowane wyzwania:

- Sygnał wymaga skalowania (obecnie 907x za duży)
- Konieczność implementacji zaawansowanego filtrowania
- Duże szумы przy ruchu pacjenta (artefakty ruchowe)
- Błędna detekcja HR przez visualizer (150 BPM zamiast rzeczywistych) z powodu problemu skalowania
- Optymalizacja dla niskich zasobów RP2040 (264KB RAM)

7 Oczekiwane rezultaty

7.1 Wkład naukowy

- Pierwsze systematyczne badanie AD8232 w kontekście deep learning
- Analiza trade-off dokładność vs zasoby dla embedded AI w medycynie
- Porównanie skuteczności architektur DL dla single-lead EKG

7.2 Wkład praktyczny

- Open-source framework dla tanich systemów EKG (<50 PLN)
- Zwalidowany pipeline od surowych danych do klasyfikacji
- Dokumentacja umożliwiająca replikację projektu

Bibliografia podstawowa

- [1] PhysioNet. *MIT-BIH Arrhythmia Database*. [DATASET]. PhysioNet, 1997. DOI: 10.13026/C2F305. URL: <https://www.physionet.org/content/mitdb/1.0.0/>.
- [2] PhysioNet. *PTB-XL Database*. [DATASET]. 2020. DOI: 10.1038/s41597-020-0495-6. URL: <https://physionet.org/content/ptb-xl/1.0.1/>.
- [3] IEEE. “Low Cost, Portable ECG Monitoring and Alarming System Based on Deep Learning”. W: *IEEE Conference Publication*. 2020. DOI: 10.1109/ICIEA48937.2020.9231005. URL: <https://ieeexplore.ieee.org/document/9231005/>.
- [4] PMC. “Reliable ECG Anomaly Detection on Edge Devices for Internet of Medical Things Applications”. W: *Sensors* 24.7 (2024), s. 2125. DOI: 10.3390/s24072125. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12031393/>.
- [5] MDPI. “AD8232 to Biopotentials Sensors: Open Source Project and Benchmark”. W: *Electronics* 12.4 (2023), s. 833. DOI: 10.3390/electronics12040833. URL: <https://www.mdpi.com/2079-9292/12/4/833>.
- [6] MDPI. “Deep Learning-Based ECG Arrhythmia Classification: A Systematic Review”. W: *Applied Sciences* 13.8 (2023), s. 4964. DOI: 10.3390/app13084964. URL: <https://www.mdpi.com/2076-3417/13/8/4964>.
- [7] ScienceDirect. “CAT-Net: Convolution, attention, and transformer network for single-lead ECG arrhythmia classification”. W: *Biomedical Signal Processing and Control* (2024). DOI: 10.1016/j.bspc.2024.106261. URL: <https://www.sciencedirect.com/science/article/pii/S1746809424002696>.
- [8] PAR. “The ECG Signal Monitoring System Using ML and LoRa”. W: *Pomiary Automatyka Robotyka* 28.2 (2024), s. 5–12. DOI: 10.14313/PAR_252/5. URL: <http://yadda.icm.edu.pl/baztech/element/bwmeta1.element.baztech-9632528f-2215-48d5-964a-0ffffb41ad392>.